

1D CNN Autoencoder 与波形 Embedding 相似度分析报告

Bluebot Mini Wave Dataset

2026 年 5 月 28 日

1 问题定义

当前数据集中，每一条超声 ADC 波形可以表示为一个长度为 T 的一维序列：

$$\mathbf{x}_i = [x_i(0), x_i(1), \dots, x_i(T-1)]^\top \in \mathbb{R}^T,$$

其中 i 是波形编号，当前 CSV 中通常有 $T = 1024$ 个采样点，即列

$$s_0, s_1, \dots, s_{1023}.$$

目标不是先训练一个监督分类器，而是先学习一个“正常波形流形”。对于任意新波形 $\mathbf{x}_i$ ，模型输出：

$$\begin{aligned} &\text{embedding } \mathbf{e}_i \in \mathbb{R}^d, \\ &\text{reconstruction error } r_i, \\ &\text{nearest-neighbor distance } d_i, \\ &\text{nearest-neighbor similarity } c_i. \end{aligned}$$

其中 d 是 embedding 维度，当前实现默认 $d = 64$ 。

2 预处理

2.1 Baseline 去除

对每条波形，先使用前 B 个采样点估计基线：

$$b_i = \text{median}\{x_i(t) \mid 0 \leq t < B\},$$

当前实现默认 $B = 160$ 。中心化后的波形为：

$$y_i(t) = x_i(t) - b_i.$$

这样做的目的，是让模型更关注回波形状、噪声结构和局部振铃，而不是 ADC 的直流偏置。

2.2 Full 模式与 Gate 模式

当前脚本支持两种输入：

$$\mathbf{y}_i^{\text{full}} = [y_i(0), y_i(1), \dots, y_i(T-1)]^\top,$$

以及只截取回波窗口的 gate 模式：

$$\mathbf{y}_i^{\text{gate}} = [y_i(g_s), y_i(g_s + 1), \dots, y_i(g_e - 1)]^\top.$$

其中 g_s, g_e 来自已有模板学习逻辑：先从训练集均值波形中找到主回波峰值，再在峰值前后取固定窗口。Full 模式保留更多全局信息；Gate 模式更聚焦于回波区。

2.3 鲁棒尺度归一化

只使用训练集中的正常样本估计全局幅度尺度：

$$a = \max(Q_p(\{|y_i(t)| : i \in \mathcal{G}, t \in \mathcal{T}\}), a_{\min}),$$

其中 $\mathcal{G}$ 是训练用 good 样本集合， Q_p 是分位数，当前默认 $p = 99$ ， $a_{\min} = 0.05$ 。

归一化后的 CNN 输入为：

$$z_i(t) = \text{clip}\left(\frac{y_i(t)}{a}, -\gamma, \gamma\right),$$

当前默认 $\gamma = 6$ 。

3 1D CNN Autoencoder

3.1 Encoder

CNN encoder 将一维波形压缩成低维 embedding：

$$\mathbf{e}_i = f_\theta(\mathbf{z}_i) \in \mathbb{R}^d.$$

每一层 1D 卷积可写成：

$$h_{i,k}^{(\ell)}(t) = \sigma\left(\sum_m \sum_{\tau=-q}^q w_{k,m,\tau}^{(\ell)} h_{i,m}^{(\ell-1)}(t - \tau) + \beta_k^{(\ell)}\right),$$

其中 k 是输出通道， m 是输入通道， $\sigma(\cdot)$ 是 ReLU：

$$\sigma(u) = \max(0, u).$$

卷积层之后使用 max-pooling 下采样：

$$\tilde{h}_{i,k}^{(\ell)}(u) = \max_{t \in \{2u, 2u+1\}} h_{i,k}^{(\ell)}(t).$$

当前实现使用三次 $2 \times$ pooling，因此长度从 T 变为：

$$T' = \frac{T}{8}.$$

对于 $T = 1024$ ，有 $T' = 128$ 。

最后展平并映射到 embedding：

$$\mathbf{e}_i = W_e \text{vec}(\mathbf{h}_i^{(L)}) + \mathbf{b}_e.$$

3.2 Decoder

Decoder 从 embedding 重建原始归一化波形:

$$\hat{z}_i = g_\phi(e_i).$$

当前实现用线性层恢复到卷积特征图尺寸, 再通过上采样和 1D 卷积恢复长度:

$$\hat{z}_i = g_\phi(f_\theta(z_i)).$$

3.3 训练目标

训练目标是最小化重建均方误差:

$$\mathcal{L}(\theta, \phi) = \frac{1}{|\mathcal{G}|T} \sum_{i \in \mathcal{G}} \|z_i - g_\phi(f_\theta(z_i))\|_2^2 + \lambda \|\theta, \phi\|_2^2.$$

其中 λ 对应实现中的 `weight_decay`。

4 训练流程与数学推理

4.1 训练集合

由于当前数据主要是 good 样本, 训练集定义为:

$$\mathcal{D}_{train} = \{\mathbf{x}_i \mid \text{label}_i = \text{good}, i \in \mathcal{I}_{train}\}.$$

其中 $\mathcal{I}_{train}$ 由 `train_fraction` 和 `split_mode` 决定。当前默认

$$\text{train_fraction} = 0.70, \quad \text{split_mode} = \text{interleaved}.$$

如果使用 `temporal split`, 则前段时间样本用于训练, 后段时间样本用于验证, 更适合观察时间漂移。

4.2 训练算法

训练时, 每个 batch 的输入张量为:

$$\mathbf{Z}_{batch} \in \mathbb{R}^{N_b \times 1 \times T},$$

其中 N_b 是 batch size。对每个 batch:

$$\mathbf{E}_{batch} = f_\theta(\mathbf{Z}_{batch}), \quad \hat{\mathbf{Z}}_{batch} = g_\phi(\mathbf{E}_{batch}).$$

batch loss 为:

$$\mathcal{L}_{batch} = \frac{1}{N_b T} \left\| \mathbf{Z}_{batch} - \hat{\mathbf{Z}}_{batch} \right\|_F^2.$$

参数通过 AdamW 更新:

$$(\theta, \phi) \leftarrow \text{AdamW}(\nabla_{\theta, \phi} \mathcal{L}_{batch}, \eta, \lambda),$$

其中 η 是 learning rate, λ 是 weight decay。

每个 epoch 后, 在 validation split 上计算:

$$\mathcal{L}_{val} = \frac{1}{|\mathcal{V}|T} \sum_{i \in \mathcal{V}} \|z_i - g_\phi(f_\theta(z_i))\|_2^2.$$

最终保留 $\mathcal{L}_{val}$ 最低的模型参数; 如果 validation 集为空, 则退化为选择 train loss 最低的参数。

4.3 为什么重建误差有意义

可以把健康波形看作集中在一个低维正常流形 $\mathcal{M}$ 附近。Autoencoder 学到的复合映射可近似理解为：

$$g_\phi(f_\theta(\mathbf{z})) \approx P_{\mathcal{M}}(\mathbf{z}),$$

其中 $P_{\mathcal{M}}$ 是到正常波形流形的近似投影。因此：

$$\mathbf{z}_i \in \mathcal{M} \Rightarrow \|\mathbf{z}_i - \hat{\mathbf{z}}_i\|_2^2 \text{ 较小},$$

$$\mathbf{z}_i \notin \mathcal{M} \Rightarrow \|\mathbf{z}_i - \hat{\mathbf{z}}_i\|_2^2 \text{ 可能升高}.$$

这就是 reconstruction MSE 可以作为异常分数的原因。

4.4 为什么 Embedding 最近邻有意义

重建误差衡量模型能否重画波形；embedding 距离则衡量该波形在压缩表征空间里是否落在历史 healthy cloud 中。对任意新样本，若

$$d_i = \min_{j \in \mathcal{G}} \|\tilde{\mathbf{e}}_i - \tilde{\mathbf{e}}_j\|_2$$

很大，则说明该波形虽然可能被 decoder 重建，但其压缩模式已经远离已知健康样本。因此当前系统同时使用 r_i 和 d_i ，形成互补判断。

5 异常分数

5.1 重建误差

对任意样本 i ，定义重建误差：

$$r_i = \frac{1}{T} \sum_{t=0}^{T-1} (z_i(t) - \hat{z}_i(t))^2.$$

直觉上，如果一条波形不像训练集中学到的正常波形，autoencoder 就更难重建它，因此 r_i 会升高。

当前实现使用训练集重建误差的高分位数作为阈值：

$$\tau_{\text{suspect}}^r = Q_{99.5}(\{r_i : i \in \mathcal{G}\}),$$

$$\tau_{\text{anomaly}}^r = Q_{99.9}(\{r_i : i \in \mathcal{G}\}).$$

5.2 Embedding 距离与相似度

Autoencoder 输出的 embedding 每一维尺度不一定一致，因此先在训练集上做鲁棒标准化。对第 k 维：

$$\mu_k = \text{median}\{e_{i,k} : i \in \mathcal{G}\},$$

$$\sigma_k = \max(1.4826 \cdot \text{median}\{|e_{i,k} - \mu_k| : i \in \mathcal{G}\}, \epsilon).$$

标准化后的 embedding 为：

$$\tilde{e}_{i,k} = \frac{e_{i,k} - \mu_k}{\sigma_k}.$$

对样本 i ，在训练集 good 样本中寻找最近邻距离：

$$d_i = \min_{j \in \mathcal{G}, j \neq i} \|\tilde{\mathbf{e}}_i - \tilde{\mathbf{e}}_j\|_2.$$

d_i 越高，说明该样本在 learned embedding 空间里越不像历史正常波形。

为了更直观地输出一个 $[0, 1]$ 形式的相似度，当前实现还定义：

$$c_i = \frac{1}{1 + d_i}.$$

此外，脚本也会输出两个原始 embedding 的余弦相似度作为辅助参考：

$$\cos(\mathbf{e}_i, \mathbf{e}_j) = \frac{\mathbf{e}_i^\top \mathbf{e}_j}{\|\mathbf{e}_i\|_2 \|\mathbf{e}_j\|_2}.$$

当前实现的主判定使用最近邻距离的高分位数作为阈值：

$$\tau_{\text{suspect}}^d = Q_{95}(\{d_i : i \in \mathcal{G}\}),$$

$$\tau_{\text{anomaly}}^d = Q_{99}(\{d_i : i \in \mathcal{G}\}).$$

6 判定规则

综合重建误差和相似度，当前规则为：

$$\text{state}_i = \begin{cases} \text{anomaly}, & r_i \geq \tau_{\text{anomaly}}^r \text{ or } d_i \geq \tau_{\text{anomaly}}^d, \\ \text{suspect}, & r_i \geq \tau_{\text{suspect}}^r \text{ or } d_i \geq \tau_{\text{suspect}}^d, \\ \text{normal}, & \text{otherwise.} \end{cases}$$

这两个分数的含义不同：

指标	数学定义	物理直觉
r_i	重建 MSE	波形是否难以被正常模型重画
d_i	标准化 embedding 最近邻距离	是否远离历史正常波形
c_i	$1/(1 + d_i)$	便于阅读的相似度分数

7 为什么先用 Autoencoder

当前数据主要是 good 样本，所以监督分类器缺少负样本。Autoencoder 的优势是只需要正常样本：

$$\mathcal{D}_{\text{train}} = \{\mathbf{x}_i : \text{label}_i = \text{good}\}.$$

它学习的是正常波形的压缩表示：

$$\mathbf{x}_i \longrightarrow \mathbf{z}_i \longrightarrow \mathbf{e}_i \longrightarrow \hat{\mathbf{z}}_i.$$

当未来出现 weak signal、air、empty pipe、high noise、clipping 等状态时，理想情况下这些波形会表现为：

$$r_i \uparrow \quad \text{或} \quad c_i \downarrow.$$

8 与手写特征模型的关系

已有 one-class 模型使用人工设计的物理特征：

$$\mathbf{u}_i = [\text{baseline}, \text{noise_rms}, \text{gate_rms}, \text{snr}, \text{template_corr}, \dots].$$

CNN embedding 则是数据驱动特征：

$$\mathbf{e}_i = f_{\theta}(\mathbf{z}_i).$$

两者可以互补：

- 手写特征更可解释，适合说明异常原因。
- CNN embedding 更灵活，适合捕捉局部形状、振铃模式和复杂波形相似性。
- 如果两者同时报警，异常可信度更高。

9 实验建议

建议至少比较两组实验：

$$\text{Full input: } T = 1024, \quad \text{Gate input: } T = g_e - g_s.$$

如果 full 模式对噪声、基线漂移、非回波区域过于敏感，可以切换 gate 模式。如果 gate 模式漏掉前段噪声、削顶或全局异常，则保留 full 模式。

未来采集到明确标签后，可以进一步训练监督模型：

$$p_{\psi}(y_i | \mathbf{e}_i), \quad y_i \in \{\text{normal}, \text{weak}, \text{air}, \text{empty}, \text{noise}\}.$$

此时 autoencoder 的 embedding 可以作为分类器输入，也可以作为预训练 encoder。

10 局限性

- 如果训练集只有 good，模型只能判断“不像 good”，不能天然区分具体异常类型。
- 阈值是从当前训练集分布估计出来的，设备更换、安装方式变化、温度变化都可能导致阈值需要重估。
- 如果训练集中混入异常样本，autoencoder 可能把异常也学成正常，因此训练集应优先使用高 SQ、人工确认的 good 数据。
- Embedding 相似度依赖训练集覆盖度。如果正常状态本身有多种子模式，需要足够多样的 good 样本。

11 输出解释

脚本输出三类文件：

- `cnn_autoencoder_model.pt`: PyTorch checkpoint，包含模型参数、预处理参数和阈值。

- `cnn_embedding_report.json`: 全局报告，包括训练历史、分位数阈值、top outliers。
- `cnn_embedding_analysis.jsonl`: 每行一个样本，包含 embedding、重建误差、最近邻和最终 `cnn_state`。